

Clase Visión Artificial

2026-09-03 22:06 UTC

Recorded by


Jorge Alejandro Silvestri

Organized by

Alesio Esteban Sinopoli




Channel

General



Machine learning

Visión Artificial
Alejandro Silvestri



Los grandes problemas de machine learning

Elementos de Machine Learning



Muestra

Colección de características (features) que representan un objeto, extraídos de una imagen.



Entrenamiento

Proceso de análisis de muestras estructuradas para generar un modelo capaz de generalizar.



Modelo

Función matemática que recibe una nueva muestra y determina una respuesta o predicción.



Predicción

La respuesta final generada por el modelo para cada muestra individual analizada.

Muestra



- Una muestra es un conjunto de datos (llamados *features*) estructurados
 - en visión artificial se lo conoce como **descriptor**
 - en machine learning se lo conoce como **vector de features**
- Un modelo requiere que todas las muestras tengan la misma estructura de datos
- Ejemplo
 - invariantes de Hu de un contorno
 - cada muestra tiene 7 features, será un vector de 7 dimensiones
 - el aprendizaje automático operará en un espacio de 7 dimensiones

Tipos de Features

Cada uno de los datos de una muestra puede clasificarse en dos tipos fundamentales:



Escalares

Representan magnitudes numéricas reales.

- Ejemplo: área de una figura
- Permiten ordenamiento (mayor/menor)
- Aptos para cálculos matemáticos



Categoricos

Representan etiquetas o clases discretas (enteros).

- Ejemplo: forma de un contorno
- Comparación solo por igualdad
- No aptos para operaciones aritméticas

Etiquetas

```
1: 'person',
2: 'bicycle',
3: 'car',
4: 'motorcycle',
5: 'airplane',
6: 'bus',
7: 'train',
8: 'truck',
9: 'boat',
10: 'traffic light',
11: 'fire hydrant',
13: 'stop sign',
14: 'parking meter',
15: 'bench',
16: 'bird',
17: 'cat',
18: 'dog',
19: 'horse',
20: 'sheep',
21: 'cow',
22: 'elephant',
23: 'bear',
24: 'zebra',
25: 'giraffe',
27: 'backpack',
28: 'umbrella',
31: 'handbag',
32: 'tie',
33: 'suitcase',
34: 'frisbee'
```

Variables Categóricas

Las computadoras sólo manejan un **identificador** numérico.

Las personas asocian una **descripción** a cada etiqueta para su comprensión.

Lista de Etiquetas

- Mapeo de descripción para cada identificador.
- Utilizada exclusivamente para anotación y legibilidad humana.

Características del Identificador

- **Naturaleza:** Número entero.
- **Lógica de Comparación:** Solo por igualdad. No se ordenan ni se comparan por magnitud.
- **Sin Aritmética:** No se usan en cálculos; no se suman, multiplican ni incrementan.

Entrenamiento



Proceso en el que el algoritmo de aprendizaje analiza un conjunto de muestras elegidas para entrenar, y produce un modelo

Supervisado



- A cada muestra se le adosa la respuesta correspondiente
- El sistema aprende de estos ejemplos
- Casos: **clasificación** y **regresión**

No supervisado



- Se proporcionan muestras sin las respuestas
- Caso: **clustering**

Dataset



Conjunto de muestras para entrenamiento

Debidamente anotadas si el entrenamiento es supervisado

División recomendada del Dataset

90%

Entrenamiento

Base principal para el aprendizaje de la máquina.

5%

Validación

Ajuste de parámetros durante el proceso.

5%

Test

Evaluación final del modelo entrenado.

Modelo



Algoritmo o Función

Es la estructura base que debe ser entrenada antes de poder usarse de manera efectiva.



Pesos y Ponderaciones

Resultado del aprendizaje que típicamente se guarda en archivos externos.



Predicción e Inferencia

Un modelo entrenado se utiliza para generar predicciones (o inferencias).



Compatibilidad Exclusiva

Las ponderaciones son específicas del modelo con el que fueron creadas.

Outliers



Datos Erróneos

Son las muestras de entrenamiento que contienen errores o ruidos que no representan la realidad del modelo.



Algoritmos Robustos

Se denominan "robustos" aquellos capaces de identificar y descartar estas muestras anómalas automáticamente.



Filtrado durante el Entrenamiento

Un proceso de aprendizaje robusto identifica y descarta muestras que no respetan el patrón emergente del modelo en desarrollo.

Overfitting



Malfuncionamiento por Mal Aprendizaje

El modelo predice bien los datos de entrenamiento, pero falla con nuevos datos. Es como aprender de memoria sin comprender.



Síntoma Universal en ML

Causado por entrenamiento excesivo o modelos demasiado complejos con exceso de parámetros.



Investigación Activa

Se estudian métodos para evitarlo y determinar la cantidad óptima de muestras para el entrenamiento.



UNA PELÍCULA DE
ALEJANDRO AMENÁBAR

ETHAN HAWKE


EMMA WATSON

REGRESIÓN

EL MIEDO SIEMPRE ENCUENTRA SU VÍCTIMA

Regresión

Análisis y ajuste de datos para modelos predictivos.



Con modelo matemático

Enfoque tradicional de **data fitting** basado en leyes físicas o teóricas.



Sin modelo matemático

Uso de funciones multiparamétricas flexibles:




- Polinomios de orden elevado
- Series de Fourier
- Modelos de caja negra (ML)

Riesgo crítico: Overfitting

El modelo "memoriza" el ruido en lugar de aprender el patrón real.


Overfitting

- la función multparamétrica tiene tantos parámetros, que puede aprender de memoria las mediciones, y no generaliza



Regresión

Análisis y ajuste de datos para modelos predictivos.



Con modelo matemático

Enfoque tradicional de **data fitting** basado en leyes físicas o teóricas.



Sin modelo matemático

Uso de funciones multiparamétricas flexibles:




- Polinomios de orden elevado
- Series de Fourier
- Modelos de caja negra (ML)

Riesgo crítico: Overfitting

El modelo "memoriza" el ruido en lugar de aprender el patrón real.

Overfitting

- la función multiparamétrica tiene tantos parámetros, que puede aprender de memoria las mediciones, y no generaliza



Solución al overfitting



Mayor volumen de datos

Aumentar la cantidad de ejemplos para mejorar la generalización.



Menor exposición a los datos

Reducir la tasa de aprendizaje para evitar ajustes excesivos.

Enfoque en Machine Learning

- Diferencias clave con **data fitting** tradicional.
- Procesamiento incremental: no considera todos los datos a la vez, sino de a uno por vez.
- Entrenamiento iterativo: recorre varias veces todo el dataset.
- Impacto temporal: el proceso de entrenamiento es significativamente más demorado.

Proceso de entrenamiento

Dividir el dataset en 3 partes

90% Entrenamiento

5% Validación



5% Test final

Fases del Entrenamiento

- **Ciclos Iterativos (Épocas):** Recorrer el dataset de entrenamiento N veces de forma completa.
- **Validación Intermedia:** Después de cada época, se evalúa el progreso sobre datos de **validación** no vistos.
- **Evaluación Final:** Una vez concluido el proceso, se mide el éxito definitivo con el dataset de **test**.


Regresión con perceptrones multicapa

redes neuronales



gradiente
descendiente a
partir de una
loss function


backpropagation

A group of Argentine football players in white and light blue striped jerseys are celebrating on a field. One player is jumping over the others, and they are all smiling and hugging. The background is a blurred stadium.


Clasificación

Clasificación


- **asignar una etiqueta o clase** a una instancia de datos basándose en sus características observadas
- las clase se suelen denominar **categorías**



Clasificador por árbol de decisión binaria




- Cada nodo es una decisión
 - compara un feature con un umbral
 - bifurcación binaria: si es mayor o no
- Profundidad del árbol
 - cantidad de decisiones para llegar a la hoja
 - **hoja** es el final de la rama
- En cada hoja hay una respuesta: la clase resultante
 - varias hojas pueden indicar la misma clase
- El modelo resultante del entrenamiento es el árbol de decisión
 - qué feature y qué umbral corresponde a cada nodo




Clasificación con perceptrones multicapa

- Las redes neuronales computan valores reales
 - no operan con etiquetas
 - su naturaleza les impide realizar una clasificación
- Clasificación con regresiones
 - una regresión para cada etiqueta
 - expresan la **confianza** para esa etiqueta
 - entre 0 y 1
 - se construyen con 2 o 3 capas



Clasificar naranjas de exportación


- machine learning cuenta con soluciones a muchos problemas especializados
- a modo de ilustración, el siguiente ejemplo muestra de qué manera se logra linealizar un problema que originalmente no era linealmente separable



Clustering



Clustering con K-Means



K-Means es un algoritmo que requiere definir previamente el número de clusters.

Resultados Clave:


- **Etiquetas:** Cada muestra recibe un ID (0, 1, 2...).
- **Centroides:** Calculados como el centro de masa.
- **Compactación:** Varianza intra-cluster (suma de distancias al cuadrado).

*El clustering es el pilar del **aprendizaje no supervisado**.*

Clustering de rostros


- a partir de descriptores faciales
- agrupa descriptores similares





Responsible AI

Prejuicios




- Los modelos producidos por machine learning son **prejuiciosos** por naturaleza
- Se les pide **generalizar** reglas a partir de aspectos **superficiales**
- La distinción de generalizaciones profundas y superficiales es un tema de investigación activa

Google's Responsible AI

El desarrollo de la IA está creando **nuevas oportunidades** para resolver problemas desafiantes del mundo real.

También está planteando **nuevas preguntas** sobre la mejor manera de construir sistemas de inteligencia artificial que **beneficien a todos**.

- Mejores prácticas recomendadas
- Rectitud
- Interpretación
- Privacidad
- Seguridad



Microsoft Responsible AI

- Fairness
 - AI systems should treat all people fairly
- Reliability & Safety
 - AI systems should perform reliably and safely
- Privacy & Security
 - AI systems should be secure and respect privacy
- Inclusiveness
 - AI systems should empower everyone and engage people
- Transparency
 - AI systems should be understandable
- Accountability
 - People should be accountable for AI systems



Resumen

Secuencia de ML

01 **Identificar el tipo de problema**
Clasificación, regresión, etc.

02 **Definir la muestra y features**
Elegir variables representativas para el modelo.

03 **Elegir la máquina adecuada**
Evaluar performance, facilidad y complejidad de configuración.

04 **Elaborar el dataset**

- Conjuntos de entrenamiento y validación
- Anotación (supervisado) y variedad de casos.

05. Entrenar
Ajuste del modelo con los datos.

06. Validar
Inferencia sobre conjunto de validación.

No perder de vista lo importante

PRIORIDAD 1

Definir los features

Es el factor más determinante para el éxito del modelo.

PRIORIDAD 2

Definir el dataset

La calidad y representatividad de los datos es fundamental.

PRIORIDAD 3

Elegir máquina y parámetros

Es lo menos importante al inicio.

Es habitual repetir el entrenamiento con varias máquinas y parámetros para comparar resultados.



Entrenamiento, Validación y Parámetros



División de Muestras

Las muestras iniciales se dividen al azar y sin sesgo para asegurar la integridad del proceso.

- Grupo para entrenamiento
- Grupo para validación



Optimización de Parámetros

Proceso iterativo para encontrar la configuración óptima de la máquina.

- Se repite el ciclo de entrenamiento y validación con distintos parámetros.
- Se eligen los parámetros con mejores resultados.
- Uso de conjuntos de muestras consistentes en cada ciclo.

3 programas



Extractor de Features

Una aplicación analiza cada imagen y genera el vector de features para cada muestra.



Entrenador

Ejecuta el entrenamiento sobre las muestras y genera un modelo.

Se puede repetir con varios parámetros y máquinas hasta alcanzar resultados deseables.



Clasificador

- Uso del modelo para inferencia y ejecución.
- Utilizado inicialmente para validación.



Machine learning



Archivo Editar Ver Insertar Formato Diapositiva Estructura ...



Presentación de diapositivas



Actualizar



Ajustar



Tr



Fondo

Diseño

Tema

Transición



32



33



34



35



35 diapositivas en total

Enlaces

- [Referencia de OpenCV](#)
- [Responsible AI](#)
- [Tutorial](#)
- [Introducción a machine learning en OpenCV](#)
- [Visualize a Decision Tree in 4 Ways with Scikit-Learn and Python](#)

Ejemplos

- [Handwritten Digits Classification: An OpenCV SVM Tutorial](#)
- [OCR of Hand-written Data using SVM](#)
- [Entrenamiento de SVM con HOG](#)
- [K-Means](#)



Mejorar esta diapositiva



En 2022 se agregó la sección Ejemplos de clasificación con SVM, con diferentes kernels



Diapositiva



Contenido multimedia



Cargas



Grabar



Transformar





Warp ☆ 📁 ☁

Archivo Editar Ver Insertar Formato Diapositiva Estructura ...



Presentación de diapositivas



Actualizar



Ajustar ▾



Tr



Fondo

Diseño

Tema

Transición



1



2



3



4



5



Mejorar esta diapositiva



versión 25c2

Warp introduce las transformaciones geométricas aplicadas a imágenes.



Diapositiva



Contenido multimedia



Cargas



Grabar



Transformar





Warp



Archivo Editar Ver Insertar Formato Diapositiva Estructura ...




Presentación de diapositivas



Actualizar



1




2



3



4



Mejorar esta diapositiva



versión 25c2
Warp introduce las transformaciones geométricas aplicadas a imágenes.


- Diapositiva
- Contenido multimedia
- Cargas
- Grabar
- Transformar



WARP

Visión artificial
Alejandro Silvestri

Transformaciones geométricas




- Muchas operaciones de procesamiento de imágenes consisten en cambiar el color de los píxeles
- Las transformaciones geométricas consisten en “mover” esos píxeles
 - **dst**: imagen destino
 - **src**: imagen origen
 - pegan en una coordenada de **dst** el color de un píxel obtenido de otra coordenada de **src**
- La operación consiste en determinar la coordenada de origen para cada píxel destino

- Transformación geométrica
 - convierte una coordenada de la imagen origen en una coordenada de la imagen destino
- Warp
 - significa **deformación**
 - aplica una transformación geométrica a una imagen completa, y genera una imagen transformada
 - se requieren la transformación y el tamaño de la imagen destino
 - el barrido se realiza siempre sobre la imagen destino

$$\text{dst}(x, y) = \text{src}(f_x(x, y), f_y(x, y))$$

Transformaciones geométricas



- Muchas operaciones de procesamiento de imágenes consisten en cambiar el color de los píxeles
- Las transformaciones geométricas consisten en “mover” esos píxeles
 - **dst**: imagen destino
 - **src**: imagen origen
 - pegan en una coordenada de **dst** el color de un píxel obtenido de otra coordenada de **src**
- La operación consiste en determinar la coordenada de origen para cada píxel destino

- Transformación geométrica
 - convierte una coordenada de la imagen origen en una coordenada de la imagen destino
- Warp
 - significa **deformación**
 - aplica una transformación geométrica a una imagen completa, y genera una imagen transformada
 - se requieren la transformación y el tamaño de la imagen destino
 - el barrido se realiza siempre sobre la imagen destino

$$\text{dst}(x, y) = \text{src}(f_x(x, y), f_y(x, y))$$


Resize

- Es la transformación geométrica más básica
- Genera una imagen de otro tamaño
 - Copia píxeles de ciertas coordenadas en la imagen origen a otras diferentes en la imagen destino
- Se puede especificar
 - el factor
 - o las nuevas dimensiones
 - un factor diferente para cada eje
 - cambio de tamaño deformado





- Es la transformación geométrica más sofisticada
- Produce una imagen a partir de otra, copiando píxeles en diferentes posiciones
 - **Mapa:** dos matrices X e Y, del mismo tamaño que la imagen a generar, guardan las coordenadas de origen de los píxeles
- Permite expresar transformaciones geométricas arbitrarias



Transformaciones de antidistorsión de lente



Transformaciones geométricas



a




b

Transformaciones geométricas




Interpolación de píxeles

- Las transformaciones geométricas computan coordenadas de origen
 - Cuando las coordenadas resultan **no enteras**, se aplica un método de interpolación
- Métodos de interpolación
 - **Nearest neighbour**
 - la coordenada más cercana
 - veloz
 - **Bilinear**
 - interpolación lineal
 - **Bicubic**
 - interpolación cúbica (tercer orden)
 - el más lento




Efecto de la interpolación lineal


nearest



bilinear



bicubic



Enlaces

- Referencia
 - [Transformaciones geométricas](#)
- Tutoriales y ejemplos
 - [Remapping](#)
 - [Twirl con remap](#)
- Documentos
 - [Bicúbica](#)



Coordenadas homogéneas



Guardado en Drive

Archivo Editar Ver Insertar Formato Diapositiva Estructura Herramientas Extensiones ...



Presentación de diapositivas



Ajustar



Tr



Fondo

Diseño

Tema

Transición



1



2



3



4



Coordenadas homogéneas



Coordenadas homogéneas

Visión artificial
Alejandro Silvestri



Diapositiva



Contenido multimedia



Cargas




Grabar



Transformar



Julio 2021
Original 2020



Coordenadas homogéneas

Visión artificial
Alejandro Silvestri



Conceptos matemáticos

- **$y = A x$** transformación lineal
 - A cuadrada e invertible, rango completo
- **$A x = 0$** ecuación homogénea
 - A rectangular o rango incompleto, infinitas soluciones en un subespacio
- **$y = A x + b$** transformación afín
 - Ecuación de la recta



GONZALEZ NICOLAS MATIAS ✂



INTRIERI GABRIEL YAMIL ✂



ROSANO MATIAS AGUSTIN ✂



BOBBIO FEDERICO NAHUEL ✂

Alesio Esteban Si



CASTRO EVELYN SOFIA ✂



BARBARO LEONARDO DOMINGO ✂



GONZALEZ AGUSTIN ELIAS ✂



MIRANDA SERGIO JAVIER ✂



ALONSO JUAN IGNACIO ✂




INTRIERI GABRIEL YAMIL ✂



ROSANO MATIAS AGUSTIN ✂

SEELE
01
SOUND
ONLY

Alesio Esteban Sinopoli ✂



CASTRO EVELYN



ORELLANO NAZARENO AZAF ✂



LOPEZ FERME NAHUEL EZEQUIEL ✂



GONZALEZ FACUNDO EMANUEL ✂



OJEDA ERNESTO ✂



ORELLANO NAZARENO AZAF 



OJEDA ERNESTO 